

基于彩色眼底照片的近视性黄斑病变病灶分割的 Deeplabv3+实现

周旭东, 张晨阳, 张颖捷

摘要: 在全球范围内, 近视性黄斑病变 (MM) 是视力损害和法定失明的主要原因之一, 在眼底镶嵌阶段后病变快速发展, 因此, 对定义三类 “Plus” 病变, 包括漆膜裂纹 (LC)、脉络膜新生血管 (CNV)、Fuchs 斑点 (FS), 的眼底图像识别与分割任务在临床上有重要意义。由于传统人工分割较依赖于经验且效率受到限制, 近年来不断发展的深度学习方法有能力标记分割出病变区域, 并为临床工作提供辅助, 本团队基于 MICCAI MMAC 2023 提供的彩色眼底照片数据集, 成功实现了近视性黄斑病变病灶分割这一任务模型, 通过训练, 本团队建立了一套有效分割三类 “Plus” 病变区域的模型系统。针对此任务, 本团队采用 Deeplabv3+模型作为基础, 使用 Dice Loss 损失函数以及 adam 优化器, 经过调试训练最终得到理想模型。经过本地测试与提交测试, 这一套模型系统的有效性得到证明, 并且排名跻身于 Further Test Phase 的 TOP3。

Deeplabv3+ Implementation for Myopic Macular Lesion Segmentation Based on Colored Fundus Photos

Xudong Zhou, Chenyang Zhang, Yingjie Zhang

Abstract: In a global context, myopic macular (MM) stands as one of the major causes of visual impairment and legal blindness. MM progresses more quickly after the stage of tessellated fundus, hence identifying and segmenting the three defined 'Plus' lesions – including lacquer cracks (LC), choroidal neovascularization (CNV), and Fuchs spots (FS) – from fundus images hold significant clinical relevance. Traditional manual segmentation, relying on experience, has been limited in efficiency. In recent years, continually evolving deep learning methodologies have exhibited the capability to locate and segment lesion areas, serving as an auxiliary tool in clinical practices. Leveraging the colored fundus photo dataset provided by MICCAI MMAC 2023, our team achieved successful segmentation of myopic macular degeneration lesions. Through rigorous training, an effective model system for segmenting the three 'Plus' lesions was developed. For this task, the foundational Deeplabv3+ model, coupled with the Dice Loss function and Adam optimizer, was adopted and fine-tuned to derive the target model system. Local and submission tests confirmed the effectiveness of this model system, positioning it within the top 3 in the Further Test Phase.

Key word: Myopic maculopathy Color fundus image Semantic image segmentation
deep learning

1 简介与意义/Introduction

1.1 项目意义和依据/Significance

眼底疾病，尤其是近视性黄斑病变，是全球范围内导致视力障碍和法定失明的主要原因之一。随着近视患者数量的增加，对于快速、准确地进行黄斑病变分析和诊断的需求日益迫切。本项目旨在通过引入深度学习技术，特别是语义分割网络（如 DeepLab），实现对近视性黄斑病变 plus 病变的自动化分割，为医生提供更迅速、准确的临床辅助工具，提高黄斑病变的早期诊断准确性。

近视性黄斑病变 plus 病变的自动化分割对于眼科医生的临床工作具有重要的意义。通过借助深度学习方法，我们可以在眼底图像中准确地标记出病变区域，辅助医生进行更精准的诊断。这不仅可以提高诊断效率，还有助于早期发现黄斑病变的迹象，可以提供早期干预和定制化治疗，有助于防止病情的进一步恶化，最终降低患者视力受损的风险。

目前，眼科医生主要依赖于手动检查眼底图像，标记出黄斑病变 plus 病变区域，这一过程耗时且容易受到医生个体经验的影响。现有的自动化分割方案在处理近视性黄斑病变 plus 病变时仍面临一些挑战，例如病变区域的复杂形态、不同病变之间的相互影响等。因此，需要一种更为准确、稳健的算法来应对这些技术难题。

本团队的研究将以语义分割网络（如 DeepLab）为基础，通过大量标注好的眼底图像数据集进行模型训练。我们将关注算法在分割近视性黄斑病变 plus 病变方面的性能表现，力求在准确性和鲁棒性上取得平衡。我们的工作流程将包括数据预处理、模型训练、验证和测试等环节，确保算法能够适用于不同类型的眼底图像，具备一定的泛化能力。最终，本团队的研究成果通过了本地测试和提交测试，在本地测试中验证集的平均 Dice Loss 位列比赛第 9 名，提交测试中测试集的平均 Dice Loss 位列同期第 3 名，比赛第 8 名。

优点和特色方面，本团队的工作将充分利用深度学习技术在图像分析领域的优势，通过端到端的学习方式，使模型能够自动学习并理解眼底图像中的黄斑病变 plus 病变特征，避免了手动设计特征的复杂性。同时，我们将关注模型的可解释性，以便医生能够理解算法的分割结果，增加医疗决策的信任度。

1.2 本方法/系统框架/Article Structure

本系统主要建立在 Deeplabv3+模型的基础上构建，下图 1-1 展示了 Deeplabv3+的结构。彩色眼底照片进入 Encoder 编码器，经过 DCNN 空洞卷积，多尺度地将特征传入卷积层，经过一系列卷积池化工作后，得到特征图。特征图转入 Decoder 解码器，解码器接受特征图与编码器中空洞卷积结果，逐层卷积复原对象，得到预测遮罩。训练过程与其他神经网络并无太大区别，模型通过比较预测结果与验证集实例，根据损失函数后向传递修正参数即可。

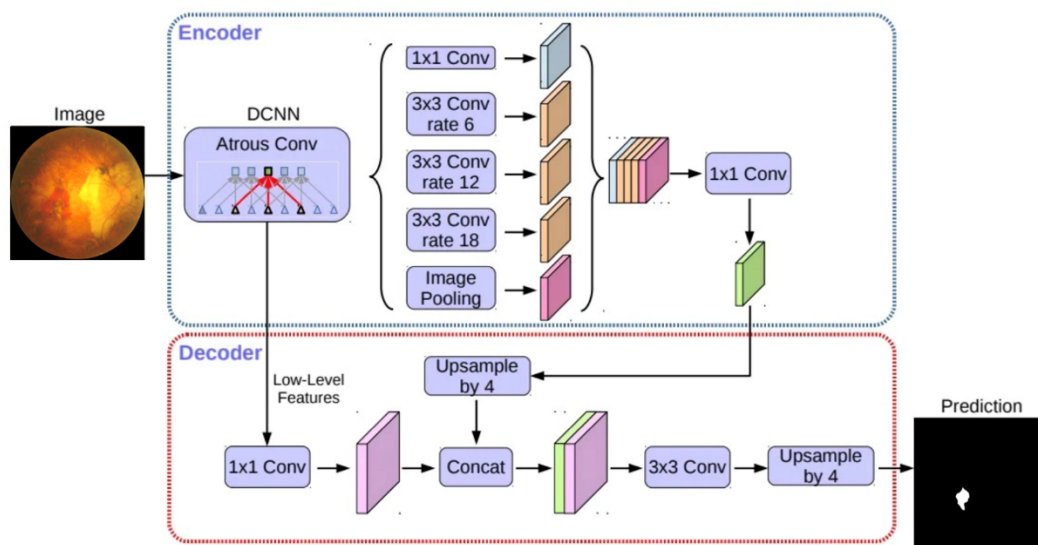


图 1-1 Deeplabv3+[1]

2 相关工作/Related Works

近年来，随着深度学习技术的不断发展，眼底图像分析领域取得了显著的进展。以下是关于近视性黄斑病变检测、医疗影像语义分割网络及其临床应用的相关工作综述。

近视性黄斑病变检测：Jia Tang 等人提出了一种基于深度学习的系统，旨在自动分级近视黄斑病变、诊断病理性近视并进行病灶分割。研究使用 ResNet-50 网络进行分类模型的建立，并采用 DeepLabv3+网络实现病灶识别的分割模型。通过这两个模型的结合，形成了基于分类和细分的共同决策模型。该模型在自动化、准确性和病变进展监测方面取得了显著成果[2]。Li 等人提出了一种双流 DCNN (DCNN- ds)模型，通过颜色直方图分布优化方法，从原始眼底图像中感知特征，实现了对不同近视水平的分类，包括无近视、棋盘状眼底和病理性近视。该方法具有高灵敏度、特异性和 AUC，显示出在自动识别近视黄斑病变方面的潜力[3]。Lu 等人的研究致力于开发深度学习系统，通过 META-PM 分类系统对彩色眼底图像进行分类，检测病理性近视和近视性黄斑病变。该系统在测试和外部验证数据集中表现出强大性能，可与眼科医生和视网膜专家媲美，为大规模近视人群的筛查提供了可行性[4]。Li 等人通过一项为期 2 年的纵向研究，探讨了脉络膜厚度(CT)对近视黄斑病变进展的影响。研究结果表明，脉络膜厚度是影响病变进展的重要因素，具有较高的预测准确性，为近视黄斑病变的早期预测提供了有力支持[5]。随着深度学习模型在医学图像分析中的广泛应用，对模型的可解释性要求也日益提高。一些研究关注于将深度学习模型的输出与病理特征关联起来，以增强模型的可解释性，提高医生对分割结果的信任度。这对于临床应用中的决策支持至关重要。

医疗影像语义分割网络：Tran 等人提出了一种多层 U-Net (Un-Net) 网络模型，用于肝脏

及肝脏肿瘤的 CT 图像分割。该模型在 U-Net 的基础上进行了改进，引入了多层结构（U n -Net），将卷积单元的输出特征作为跳跃连接，以更充分地利用卷积单元中的输出特征。实验结果表明，在 LiTS 和 3DIRCADb 两个公共数据集上，提出的模型在肝脏和肝脏肿瘤的分割任务中取得了优越的性能，Dice's 相似性系数（DSC）分别达到 96.38%和 73.69%[6]。Azad 等人提出了 TransDeepLab，这是一种基于 Transformer 的医学图像分割模型，对 DeepLab v3+进行了扩展。该模型利用分层 Swin-Transformer 和移位窗口对 Atrous Spatial Pyramid Pooling(ASPP) 模块进行建模。通过引入 Transformer，TransDeepLab 更好地捕获了全局信息，相较于传统的 CNN 模型，在医学图像分割任务中取得了显著性能提升[7]。Ibtehaz 和 Rahman 提出了 MultiResUNet，这是对传统 U-Net 架构的改进，用于多模态生物医学图像分割。通过在 U-Net 的基础上进行修改，提出的 MultiResUNet 模型在处理各种具有挑战性的数据集时取得了显著的性能提升。在五个不同的数据集上，MultiResUNet 相较于传统 U-Net 在性能上的相对提升分别为 10.15%，5.07%，2.63%，1.41%和 0.62%。该模型在理想图像和挑战性图像方面均表现出色[8]。

图像分割的临床应用：Angelini 等人对胶质瘤的动态变化进行了广泛的研究，强调了计算机生长模型在临床应用中的重要性。他们提到了虚拟大脑的计算机生长，通过地图集和患者大脑 MRI 数据之间的注册，实现了真实的 3D 分段进化匹配。该文系统回顾了现有的计算任务，包括图像分割、图像配准以及硅生长模型。临床应用方面，作者强调了这些计算模型在胶质瘤治疗管理中的潜在重要性[9]。Luo 等人关注深度学习在口腔医学图像分割方面的临床应用。他们系统地回顾了基于深度学习的口腔医学图像分割方法，并分析了它们的优缺点。文中探讨了数据源、骨干网络和任务形式等主要方面。此外，文中还提到了这些深度学习方法在口腔医学领域的临床应用，强调了它们在医学图像分析中的潜在作用[10]。Luo 等人针对腹部器官分割任务建立了一个名为 WORD 的大规模数据集，并进行了相关研究。他们指出，全腹部器官分割对于诊断腹部病变、放射治疗和随访至关重要。研究中，提出的 WORD 数据集包含 150 个腹部 CT 卷（30495 张切片），每个卷有 16 个器官，具有精细的像素级注释和基于涂鸦的稀疏注释。该数据集为腹部多器官分割任务提供了新的基准，同时通过邀请三名经验丰富的肿瘤学家对模型预测进行修订，衡量了深度学习方法与专业医生之间的差距。这项工作不仅为腹部多器官分割提供了新的基准，还探索了在大规模数据集上的推理效率学习和基于涂鸦的注释有效学习[11]。

本团队将采用 DeepLabv3+等语义分割网络，通过标注数据进行训练，以应对近视性黄斑病变 plus 病变的复杂性。我们的工作将注重模型的可解释性，同时关注临床应用中的实际需求，力求为医生提供更可靠的辅助信息。

3 研究内容与方法(或算法)/Contnts and Methods(or Algorithm)

3.1 计算资源准备

本团队使用 Google Colab 作为本次实验的计算平台。相较于校内交我算资源，无需排队

和配置复杂的环境。

3.2 数据准备和产生

3.2.1 数据来源

报 名 MICCAI MMAC 2023 - Myopic Maculopathy Analysis Challenge - Task 2 比赛 <https://codalab.lisn.upsaclay.fr/competitions/12476#participate>，从网站上下载对应训练集与验证集。其中，Images 中给出了原始 rgb 彩色图像，GroundTruths 中给出[0, 255]二值 mask 图像。每个 2D 图像均为尺寸 800*800 的 .png 文件。

其中包含了三类病变 Lacquer Cracks，Choroidal Neovascularization 与 Fuchs Spot。接下来将逐个介绍各病变及其对应的图像特征。**Lacquer Cracks**：在近视性黄斑病变中常见的一种表现，其特征为黄斑区域的色素上皮发生撕裂，形成类似裂纹的病变；通常在视网膜黄斑区域可见，呈线性或弯曲状的裂纹；这些裂纹可能在色素上皮层中产生黑色的变化，而在成像中呈现出一些特殊的形状。**Choroidal Neovascularization**：指在脉络膜区域发生的异常血管生成；这种新生血管通常是不规则的，容易导致渗漏和出血；在成像中，Choroidal Neovascularization 可能表现为脉络膜区域异常的血管密度和形态，可能伴有渗漏或出血的迹象；在荧光血管造影（fluorescein angiography）图像中，这些新生血管通常会显示为荧光泄漏。**Fuchs Spot**：一种在视网膜中央区域出现的小型脱离的区域，通常与脉络膜的血管渗漏和出血有关；在图像上表现为视网膜中央区域的小型脱离或脱离痕迹，这些斑点可能在彩色照片或 OCT（光学相干断层扫描）图像中可见。

为获取更好的模型泛化和学习曲线，对训练集进行统计如表 3-1。

Task	Training Set	Validation Set
Lacquer Cracks	63	12
Choroidal Neovascularization	32	7
Fuchs Spot	54	13

表 3-1 训练集数据量统计

展示数据集如图 3-2。




图 3-2 数据集以及遮罩图像

发现 Choroidal Neovascularization 的训练集和验证集相较于其他两类病变明显偏少，在相同参数和模型的情况下对三类进行训练时更容易发生过拟合现象。并且三类验证集与训练集的比例并非固定，在预处理时需要手动调整划分训练验证集。

3.2.2 数据预处理

为了更进一步地使得训练预测过程与任务数据集相匹配，本团队将数据集内容进行了预处理，预处理的内容可以主要分为以下几个方面。

第一是对遮罩图像做归一化处理。数据集提供的遮罩文件是 $[0, 255]$ 的，适宜肉眼观察的图像文件，但在深度学习中，对这类图像做归一化处理为 $[0, 1]$ 是相当有必要的。归一化能使得图像在输入过程中更加适应神经网络映射需求，在传递计算中更能避免溢出或梯度消失等问题，在训练模型中更快学习、加速收敛。以上优势都是常规图像在深度学习中所不具备的。在实现过程中，本团队采用基于 PIL 的一套方法完成归一化处理。

第二是对数据集进行数据增强。在本项目中，由于训练数据集相对较小，本团队采用了数据增强的方法对数据集进行扩充，具体操作包括：对图像进行缩放以及长和宽的扭曲，对图像

进行翻转、高斯模糊、旋转，对图像进行色域变换等。

3.3 模型选择与训练

基于黄斑病病理图像特征，本团队分析该任务属于典型的语义分割问题。其目标在于将眼底图像中的病变区域基于整体图像位置精确分割，而不关注病变块的每个实例，这与语义分割任务的典型特征相符。基于此，本团队对语义分割模型进行了研究与探讨。

一般地，语义分割模型建立在 CNN 网络提取特征的基础上，但早期的语义分割模型陷于特征图过小无法保留信息与巨大计算量的困境，如 FCN 等原始模型。这些模型会对网络中的图片进行相当程度的压缩，导致空间信息严重损失，进一步地影响分割的准确性。

为了解决这一问题，后续的研究上，围绕两个主要思路作为解决方案，构造了一系列的模型。一种是以 U-net 为代表的架构，依靠 Encoder-Decoder 上采样下采样结构来横向传递空间信息特征。；另一种是以 Deeplab 为代表的，依靠空洞卷积维持精细度的架构。

经过比较选择，本团队最终采用了 Deeplab 系列的架构来解决本次的语义分割任务。后续会详细说明该类架构的模型细节与独特优势。

3.3.1 DeepLabv3+模型

前文业已提到，Deeplab 模型主要采用了空洞卷积的技术来提供语义分割的性能。空洞卷积技术向卷积核中引入了“膨胀率”概念，在卷积核中引入零元素空洞来扩大卷积核的感受野，从而更好地捕捉到图像更广更全局的信息。早期的 Deeplabv1 模型在 VGG-16 网络的基础上架构而成，通过略过尾部池化层保持准确度，并通过空洞卷积技术保持感受野。Deeplabv2 引入 ASPP 技术强化了模型识别不同尺寸物体的能力，Deeplabv3 引入 Multi-Grid 策略强化空洞卷积，向 ASPP 加入新的结构以处理部分极端情况导致的退化。

而 Deeplabv3+引入了 Encoder-Decoder 体系，将 Deeplabv3 的 DCNN 部分作为 Encoder 模块，并添加了特征图采样这一简单而有效的 Decoder 模块。Deeplabv3+相比于过去几代，在保持大尺寸多尺度图像处理能力的同时，在小尺度细节上有了突破，这一特点使得 Deeplabv3+模型相当适合本任务。

下图 3-2 展示了 Deeplabv3+的创新性设计。图（a）展示的是原始的 Deeplabv3 架构，显式说明了空间金字塔池化模块，以及不同尺度的空洞卷积；图（b）展示的则是传统的 Encoder-Decoder 结构，编码器与解码器两相对称。图（c）为最终结合的 Deeplabv3+架构，利用 Deeplab 系列的固有能力作为编码器，提供丰富的语义信息；并设计解码器恢复具体的边界细节，弥补了小尺度细节上的不足。

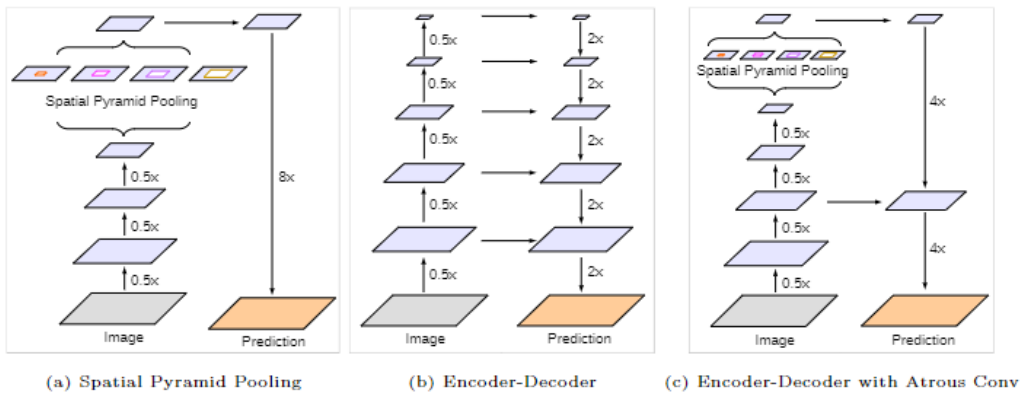


图 3-21 Deeplabv3+的 Encoder-Decoder 设计[1]

相比于 Deeplabv3+, U-net 网络在小尺度细节上固然有其固有优势。但在实际训练中, U-net 模型表现出了不可挽回的过拟合现象, 参数调整相对困难, 故最终本团队选择了 Deeplabv3+ 作为实践模型。

3.3.2 损失函数与优化器的选择

原版 DeeplabV3+ 采用 Cross-Entropy Loss 作为损失函数和 SGD 作为优化器。本团队创新性地引入 Dice Loss 作为损失函数和 Adam 作为优化器, 使得网络更适宜黄斑病医学图像分割。

$$L_{dice} = -\frac{2}{|K|} \sum_{k \in K} \frac{\sum_{i \in I} u_i^k v_i^k}{\sum_{i \in I} u_i^k + \sum_{i \in I} v_i^k}$$

其中, L 为 Dice Loss, 衡量模型预测与真实标签之间的相似度。 K 表示任务中的类别数, 在本次分割任务中, $K=2$ 。 k 表示分类索引, 变化范围为 $0-K$ 。 I 表示图像或体积中的像素或体素的集合。 u_i^k 表示模型对样本 i 中属于类别 k 的像素或体素的预测概率。 v_i^k 表示样本 i 中属于类别 k 的像素或体素的真实标签。

在黄斑病分割任务中, 不同病例对应的特征和像素大小差异较大, 交叉熵损失在训练过程中可能偏向于多数类别。Dice Loss 的计算不依赖于像素数量, 因此对于差异大的数据更加稳健。其次, Dice Loss 通常更能捕捉到模型对目标边界的精确预测。因为 Dice Loss 关注于预测结果与真实标签的重叠程度, 更侧重于模型在目标区域的精确性。并且, 与全局性的交叉熵损失相比, Dice Loss 是一种局部性损失, 主要关注于模型预测结果与真实标签的相似度。这使得 Dice Loss 在处理任务中的一些局部结构、边界等方面更为敏感。

在优化器的选择上, 本团队使用 Adam 替代 SGD。Adam 使用自适应学习率, 每个参数都有自己的学习率, 这使得 Adam 能够更灵活地适应不同参数的梯度变化, 对于医学影像分割中的复杂结构和不均匀分布的数据, 自适应学习率通常能够更好地适应不同特征的变化。并且, Adam 引入了动量的概念, 它通过估计梯度的一阶和二阶矩来计算参数更新。这有助于克服 SGD 中可能出现的在存在大量平坦区域时难以收敛到理想状态的问题。在实际使用中, SGD 呈现出下降更快的特点, 但极其容易陷入验证集性能饱和情况, 到 $\text{val loss}=0.7$ 左右后难以继续收敛,

后续增加 epoch 也无法继续优化。而使用 Adam 后虽然 val loss 下降较慢，但能突破 0.7 的“平坦区域”进入“峡谷”之中并收敛到 0.23 左右，从而获得远超 SGD 的效果。此外，在医学影像分割中，由于分割任务通常涉及到边界和细小结构，导致梯度较为稀疏。Adam 对于稀疏梯度的适应性更好，相比 SGD 更容易处理这种情况。Adam 通常不需要手动调整学习率，这使得训练过程更为简便。相比之下，SGD 通常需要经过调整学习率的阶段，这可能需要更多的试验和经验。

3.3.3 训练参数

在训练过程中，某些超参数的调整可能对模型的性能产生显著影响，导致预测误差大幅增加，甚至可能导致对病变区域的丢失。本研究团队提出了一种可能的超参数组合（如表 3-2 所示），该组合在针对该比赛数据集进行训练时表现出良好的效果。

Model	Backbone	Input shape	Loss Function	Epoch
Deeplabv3+	Mobilenet	[800, 800]	Dice	300
Batch size	Initial learning rate	Min learning rate	Optimizer	Class num
2	5E-04	5E-09	Adam	2

表 3-2 2 训练超参数组合

3.3.4 分割效果可视化

使用 pyplot 对 log 中的 Training Loss 与 Validation Loss 进行可视化如图 3-2 所示，可以看到 Adam 优化器带来的持续有效的下降效果，在 50 代后逐渐开始收敛，在 250 代左右收敛到相对理想的状态。




图 3-3 训练过程 loss 变化图

4 实验结果与分析/Experiment Results and Analysis

本团队最终采用了 Deeplabv3+模型，并用比赛提供的数据集 “ 2. Segmentation of Myopic Maculopathy Plus Lesions ” 作为训练模型的训练集与验证集进行模型训练，并得到训练模型。

本团队采用的模型是特别适应于二元语义分割任务，对于三个语义分割子任务 LC、CNV、FS，分别加以训练，最终得到了三个分别针对对应任务的模型及其参数，并选择出了各自对应的 best_epoch_weights.pth。下图 4-1 展示了模型对部分样例的病变部位分割结果，选取了三个子任务中最具代表性的各一组样例进行呈现说明。特别地，为了充分展示预测效果，Prediction 的图例经过了叠加等图像操作，并不完全等同于预测实际输出。

而实际上，肉眼识别对模型能力的判断是极为有限的定性判断。为了定量地对分割结果做出初步判定，本团队设计了简单的 rank 方法进行本地测试，用验证集的预测结果计算 Dice Loss 值以评价模型的能力。下表 4-1 展示了模型在验证集上预测的 Dice Loss。

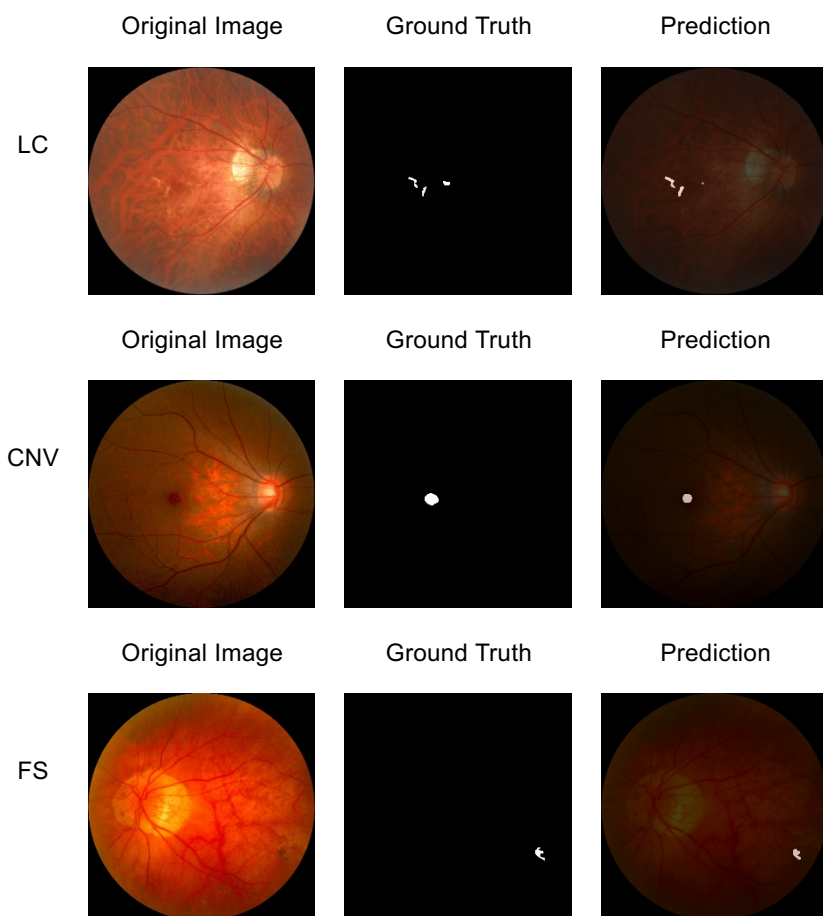


图 4-1 预测结果遮罩及组合

子任务	Avg dice loss
Lacquer Cracks	0.6544349099861199
Choroidal Neovascularization	0.4622202665779083
Fuchs Spot	0.7685648654119513

表 4-1 Dice Loss 评估

可以看到，预测结果在病变部位的大致区域上基本准确，而在小处细节上还存在一定的误差。**rank** 的计算结果也为此提供了数据上的佐证。由此，本团队可以简单总结出模型的语义分割能力：模型在全局检索出病变可能区域的能力较为优秀，而在确定具体病变区边缘的能力还存在一定局限。

分析认为，这种能力的缺点是多方面因素造成的，其一是由于 Deeplab 模型在小处注意力的劣势，和特别强化注意力的模型难免存在差异；其二是由于数据集大小，此类经过标注处理的医学影像极为有限，这也为模型的预测能力无形中添加了了上限。

最终本团队对训练所得模型进行了提交测试，并对结果进行了横向对比。本地测试中三个任务的平均 Dice Loss 分别为 0.6544、0.4622、0.7686，总体平均值 0.6284，上述四个指标分别位列往期比赛中第 10、10、8、9 名；提交测试中三个任务的平均 Dice Loss 分别为 0.6142、0.4352、0.6630，总体平均 0.5708，位列往期比赛第 8 名、同期第 3 名。

5 特色与创新/Distinctive or Innovation Points

本团队通过在 DeepLabV3+中进行优化器和损失函数的修改，成功解决了原始版本在医学影像分割任务中面临的两个主要问题：

优化器的改进： 原始版本的 DeepLabV3+可能在训练过程中遇到难以正常收敛的问题。为了解决这一问题，团队选择了 Adam 优化器。Adam 优化器以自适应学习率和动量的方式更新模型参数，这对于医学影像分割等复杂任务非常有效。自适应学习率可以帮助模型更好地适应数据中的不同尺度和特征，而动量则有助于克服一些局部极小值的问题，提高了模型的收敛性和稳定性。

损失函数的改进： 针对小目标难以准确识别的问题，团队采用了 Dice Loss 作为替代。Dice Loss 是一种适用于图像分割任务的损失函数，特别擅长处理类别不平衡和强调目标边界匹配的情况。相比交叉熵损失，Dice Loss 更加关注模型预测结果与真实标签的重叠度，因此在处理小目标或者目标边界不清晰的情况下表现更好。

通过这两项关键改进，本团队成功提高了模型在医学影像分割任务中的性能。Adam 优化器的引入使得训练更加稳定，而 Dice Loss 的使用提高了模型对于小目标的准确性。这样的改进不仅使得模型更容易收敛，还提高了在医学影像领域的实际应用性能，尤其是在处理小尺寸结构或低对比度区域的情况下。这对于提高医学图像分割的精度和鲁棒性具有积极的影响。

此外，在本项目中，本团队还遇到以下技术问题并进行相应解决。

数据集较小： 在本项目中，由于训练数据集相对较小，不足以支撑复杂的模型训练要求，

本团队采用了数据增强的方法对数据集进行扩充，具体操作包括：对图像进行缩放以及长和宽的扭曲，对图像进行翻转、高斯模糊、旋转，对图像进行色域变换等。

数据加载速度低：在数据载入阶段，观察到数据载入速度较低，因此本团队使用多线程数据读入来进行加速，解决效果良好。

References:

- [1] Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.
- [2] Jia Tang, Mingzhen Yuan, Kaibin Tian, Yuelin Wang, Dongyue Wang, Jingyuan Yang, Zhikun Yang, Xixi He, Yan Luo, Ying Li, Jie Xu, Xirong Li, Dayong Ding, Yanhan Ren, Youxin Chen, Srinivas R. Sadda, Weihong Yu; An Artificial-Intelligence-Based Automated Grading and Lesions Segmentation System for Myopic Maculopathy Based on Color Fundus Photographs. Trans. Vis. Sci. Tech. 2022;11(6):16. <https://doi.org/10.1167/tvst.11.6.16>
- [3] Yu SS, Zhou SG, Guan JH. Software engineering data mining: A survey. Journal of Frontiers of Computer Science and Technology, 2012,6(1):1-31 (in Chinese with English abstract).
- [4] Lu, L., Zhou, E., Yu, W. et al. Development of deep learning-based detecting systems for pathologic myopia using retinal fundus images. Commun Biol 4, 1225 (2021). <https://doi.org/10.1038/s42003-021-02758-y>
- [5] Li Z, Wang W, Liu R, et alChoroidal thickness predicts progression of myopic maculopathy in high myopes: a 2-year longitudinal studyBritish Journal of Ophthalmology 2021;105:1744-1750.
- [6] S. -T. Tran, C. -H. Cheng and D. -G. Liu, "A Multiple Layer U-Net, Un-Net, for Liver and Liver Tumor Segmentation in CT," in IEEE Access, vol. 9, pp. 3752-3764, 2021, doi: 10.1109/ACCESS.2020.3047861.
- [7] Azad, R. et al. (2022). TransDeepLab: Convolution-Free Transformer-Based DeepLab v3+ for Medical Image Segmentation. In: Rekik, I., Adeli, E., Park, S.H., Cintas, C. (eds) Predictive Intelligence in Medicine. PRIME 2022. Lecture Notes in Computer Science, vol 13564. Springer, Cham. https://doi.org/10.1007/978-3-031-16919-9_9
- [8] Nabil Ibtihaz, M. Sohel Rahman, MultiResUNet : Rethinking the U-Net architecture for multimodal biomedical image segmentation, Neural Networks, Volume 121, 2020, Pages 74-87, ISSN 0893-6080, <https://doi.org/10.1016/j.neunet.2019.08.025>.
- [9] Angelini E D, Clatz O, Mandonnet E, et al. Glioma dynamics and computational models: a review of segmentation, registration, and in silico growth algorithms and their clinical applications[J]. Current Medical Imaging, 2007, 3(4): 262-276.
- [10] Luo D, Zeng W, Chen J, et al. Deep learning for automatic image segmentation in stomatology and its clinical application[J]. Frontiers in Medical Technology, 2021, 3: 767836.
- [11] Luo X, Liao W, Xiao J, et al. Word: A large scale dataset, benchmark and clinical applicable study for abdominal organ segmentation from ct image[J]. arXiv preprint arXiv:2111.02403, 2021.

时间安排与分工统计表

组员信息（含组长）			
学生姓名	周旭东	学 号	521021910829
项目分工	统筹工作，编写工具，提交测试，模型训练与优化，报告撰写等。		
学生姓名	张晨阳	学 号	521021910761
项目分工	模型规划搭建，模型训练与优化，函数优化，本地测试，报告撰写等。		
学生姓名	张颖捷	学 号	521021910642
项目分工	资料查询，模型训练与优化，优化器选择，报告撰写，ppt 制作等。		
时间安排 / Schedule	11/16 团队确立、分工 11/24~26 选题、方案制定 11/27~12/3 模型试验、方案选择 12/4~15 开发系统、本地评测 12/15~16 提交测试、报告撰写、汇报 PPT 制作		